

MDLM Commit-Readiness: 观察到的现象汇总

研究对象: Masked Diffusion Language Model (MDLM, 实验模型 Dream-7B) 核心追问: MDLM 为什么退化成自回归 (AR)? 能否真正并行生成? 本文档只汇总**实验观察到的现象**, 图片来自 `exp/out/`。

背景与核心概念

MDLM 从全 [M] (mask) 开始, 逐步把位置揭示 (**commit**) 成真实 token, 且 commit 通常不可逆。并行生成的关键问题是: **能否一次性、安全地敲定多个位置而不会后悔?**

我们定义了一个可测量的量 **Stability (跨轨迹后验稳定性)**:


Stability(位置 i) = 从当前部分揭示状态出发, 随机继续揭示其他位置, i 的预测 (argmax) 保持不变的概率。

- Stability = 1 $\rightarrow$ 现在敲定绝对安全 (**commit-ready**)
- Stability 低 $\rightarrow$ 敲定后很可能被后续揭示推翻

所有现有方法用 **confidence (predicted probability)** 决定敲不敲。我们的核心疑问: **confidence 是不是好的敲定判据?**

现象 1: commit-readiness 独立于 confidence

散点 (左): 每个点是一个位置, 横轴 predicted prob, 纵轴真实 Stability。



观察: - `Spearman(prob, stability) = 0.32` —— 两者只是**中等相关, 不是同一回事**。 - 存在大量"prob 低但 stability 高" (图左上) 和"prob 高但 stability 低"的位置。 - 右图: 用 hidden state 预测 stability ($R^2=0.34$) 明显强于只用 prob/margin ($R^2=0.11$)。

含义: 一个位置"是哪个词的把握 (confidence) "和"敲定后会不会后悔 (stability) "是两个不同的量。commit reliability $\neq$ confidence。


现象 2: commit-readiness 主要能从单个位置的 hidden state 读出 (state-local) , 但生成最早期例外

(同上图右侧柱状) 在大样本(1570)下: - hidden 单独预测 stability $R^2 \approx 0.34$; - 再加入"全局揭示了哪些位置"的信息, 仅额外提升约 +0.06。

观察: commit-readiness 主要是 state-local 的——大体只看该位置自身内部状态就能判断, 不太依赖全局。例外: 在生成最早期 (只揭示了 1-2 个 token 时), "具体哪个邻居被揭示"仍有明显影响 ($\Delta \approx 0.09$), 即早期存在真实的 **位置间耦合 (path-dependence)**, 之后逐渐消失。

现象 3: commit-readiness 信息在浅层最强 (U 形)

逐层用 hidden 预测 stability:




观察: - 第 0 层 (embedding) 几乎无信息; - **第 2 层最强 ($R^2 \approx 0.38$)**, 随后中层下降, 后层回升 —— 呈 U 形。

含义: commit-readiness 更像一种 **浅层、局部的表面可预测性统计**, 而非深层语义。(注: 浅层最强可能含位置/token 统计的 artifact, 标为待复核。)

现象 4: 模型自发生成是"边界锚点优先", 且锚点是位置性而非语义性

让模型按 confidence-first 自发揭示, 记录顺序:



观察： - 揭示顺序与"从左到右"的相关性 = **0.62** (纯 AR 会是 1.0) → **强偏 AR 但非纯 AR**。 - 相邻揭示间距 = +1 的比例约 0.53。 - 典型顺序如 [0,1,2, 句尾, 3,4, 中间...]：**先锚定句子开头连续几个 + 句尾，再往中间填**。 - 进一步检验 (Exp8)：这个"先填哪里"由**位置**驱动 (靠首尾更早，相关 -0.19)，与"是不是内容词"几乎无关 (控制位置后系数 ≈ -0.02)。

含义：确实退化成近似 AR，保留"先定边界锚点"的痕迹；但锚点是**位置性 (首尾边界)**，**不是语义性** (不是先填信息量大的内容词)。这**反证**了"先建语义核心单元(information-unit)"的假说。

现象 5 (机制)：AR 退化的根因是 "confidence 门控"

统计"confidence ≥ 0.9 才敢敲定"的位置出现在什么时候：只有 3.6% 达标，且**几乎全在上下文充分揭示之后**。


观察 → 机制：

confidence 要够高才敢敲定 → 但 confidence 只有在周围上下文揭示后才会变高 → 模型只能"等邻居揭示完再敲定自己" → 从左到右的串行 = **AR 退化**。

含义：AR 退化**不是因为语言本质是 AR**，而是因为 **"用 confidence 当敲定判据"** 这件事本身天然强制了串行。

现象 6：用 certifier (读 hidden 预测 stability) 挑 commit, 比 confidence 更可靠

模拟"一步并行敲定 top-r 比例位置"，比较被敲定位置的真实 stability (越高越安全)：




观察 (8/8 随机种子稳健)：- certifier (绿) 在所有并行度下都优于 confidence (蓝)，几乎贴合 oracle 上界 (黑虚线)。- 一步并行敲定 50% 时：confidence 出错率 5.2%，certifier 仅 1.0% —— **出错率降约 80%**。

含义：把敲定判据从 confidence 换成 certifier，能在激进并行下显著减少错误 commit。

现象 7：真实并行生成中，certifier 是更好的 planner——但优势主要在低并行、高并行时趋同

两种策略各自**真实生成整句**，独立 GPT-2 裁判测质量 (NLL 越低越好)，扫并行度 k：




观察： - certifier (绿) 在每个并行度都优于或等于 confidence (蓝)；k=1 (串行) 时差距最大 (NLL 7.5→5.2)。 - **但优势随并行度增大而缩小**，到高并行 (k≥4) 两条线**迅速趋同**。

含义： certifier 的收益**主要来自"它是一个更好的揭示顺序 planner"** (尤其低并行时)，**并未解锁"高并行不退化"**。即当前形态本质是 **planner 谱系里"更好的评分函数"**，高并行区间仍是未解决区。

现象 8：把 commit-readiness 塞进训练目标去重塑表征——无效，甚至有害

尝试用训练 (LoRA + readiness 目标) 诱导 commit-ready 表征，看能否压下高并行区间。做了两版并带对照：



观察 (高并行区间 $k \geq 4$ 平均 NLL) :

策略	简单辅助损失版	可微commit版
inference-only certifier (不训练)	6.08	6.08 (最好)
LoRA微调 + confidence (纯微调对照)	4.54	6.75
LoRA微调 + readiness planner	4.76	6.81

- 辅助损失版: 增益**全来自 LoRA 微调副作用** (对照 lora+conf 已达 4.54), readiness planner 无净贡献。
- 可微 commit 版: 训练目标反而**把模型整体搞差了** (对照从 4.54 退到 6.75), 连不训练的 certifier 都反超。

含义: 在单卡+小数据+LoRA 规模下, "训练诱导 commit-ready 表征" **无法带来超越 inference planner 的收益**, 甚至有害。readiness 信号作为**判据**有效, 作为**训练目标**与语言建模冲突。

汇总: 现象之间的逻辑闭环

- MDLM 想并行却退化成近似 AR (现象4: $L2R \approx 0.62$)。
- 根因是 confidence 门控——高 confidence 只在上下文充分后出现, 逼着串行 (现象5)。
- 存在独立于 confidence 的量 Stability, 能刻画"真正安不安全敲定" (现象1)。
- Stability 主要能从单位置 hidden 读出 (state-local, 现象2), 且藏在浅层 (现象3)。
- 用它做 certifier 挑 commit, 比 confidence 可靠 (现象6), 真实生成中是更好的 planner (现象7)。
- 但**: certifier 只在低并行占优、高并行趋同 (现象7); 把 readiness 塞进训练重塑表征无效/有害 (现象8)。

尚未解决的核心问题

- 现象 6-8 共同表明: **当前成果止步于"更好的 inference-time planner"**, 没有真正解决"如何让 MDLM 具备可靠的高并行 commit 能力"这一原始问题。

- 现象 8 暗示一个更底层的张力：“**可靠并行 commit**”与“**以 token 为生成原子**”可能本质冲突——只要生成原子是 token，confidence 就必然要等上下文充分、必然串行；在 token 粒度上加 planner 或辅助损失都绕不开这一点。
 - 由此指向 GPT 讨论最后那个尚未回答的问题：**语言模型真正的 generation primitive 是不是 token?** 若不是（而是某种 block / latent unit），MDLM 的可靠并行或许才有出口。
-

已知局限

- 单模型（Dream-7B）、英文短句、样本量有限；Stability 为蒙特卡洛近似（有噪）。
- probe/certifier 为线性；命题 C 受单卡算力限制（LoRA + 小数据）。
- 质量指标用 GPT-2 NLL（对流畅度敏感，微调过拟合会虚假拉低），需换真实下游任务指标复核。
- 结论为**强初步观察**，非定论级结果。